

Universidad Autónoma de Madrid

Escuela Politécnica Superior



Grado en Ingeniería Informática

TRABAJO DE FIN DE GRADO

TODO: TÍTULO DEL TRABAJO DE FIN DE GRADO

Javier López Cano
Tutor: Ramón Díaz Uriarte

Junio 2021

TODO: TÍTULO DEL TRABAJO DE FIN DE GRADO

Autor: Javier López Cano
Tutor: Ramón Díaz Uriarte

Dpto. de Bioquímica
Escuela Politécnica Superior
Universidad Autónoma de Madrid

Junio 2021

Agradecimientos

TODO: Agradecimientos.

“TODO: Cita relevante” TODO: Autor de la cita

Abstract

Abstract — TODO: Resumen en inglés, 250-500 palabras.

Key words — TODO: Palabras clave en inglés, separadas por coma.

Resumen

Resumen — TODO: Resumen en español, 250-500 palabras.

Palabras clave — TODO: Palabras clave en español, separadas por coma.

Índice general

Índice de tablas

Índice de figuras

1

Introducción

1.1. Motivación

El cáncer es una de las enfermedades más comunes y preocupantes en la actualidad. Concretamente, en España, en el año 2021 supuso la segunda causa de muerte más común, después de las enfermedades circulatorias y por encima de las infecciosas (que incluyen los casos de la pandemia de Covid-19). Estos preocupantes datos son el principal motivo por el que el interés por la enfermedad así como los esfuerzos en su investigación han ido en aumento durante los últimos años.

A través de la investigación se han logrado encontrar diversos tratamientos, intervenciones quirúrgicas y terapias que permiten mejorar el pronóstico de distintos tipos de cáncer, e incluso eliminarlos en algunos casos. Estos tratamientos, sin embargo, no siempre son viables o totalmente efectivos, por lo que en ocasiones, es necesario plantear un enfoque distinto, que, en lugar de centrarse en eliminar el mayor número posible de células cancerígenas, se centre en tratar de frenar la evolución del tumor, de modo que su crecimiento sea lo más lento posible. Es aquí donde aparece, entre otros posibles tratamientos, la llamada **terapia adaptativa**.

La terapia adaptativa es una estrategia de aplicación de tratamientos contra el cáncer, centrada en aplicar tratamientos distintos dependiendo de la etapa en la que se encuentre el desarrollo del tumor, con el fin de reducir su avance al mínimo posible. De este modo, se van realizando estudios acerca del estado del tumor para llevar a cabo la opción más prometedora en cada momento. Al aplicar una diversidad de tratamientos, se logran evitar algunos de los problemas más comunes de los tratamientos de cáncer, como es por ejemplo la aparición de células tumorales resistentes a ciertos tratamientos. Un ejemplo de ello suele ocurrir con la quimioterapia, ya que, en muchas ocasiones, ésta no logra eliminar

la totalidad del tumor pues algunas células pueden desarrollar una mutación que las haga menos susceptibles a ésta, es en este momento cuando entra en juego la estrategia de la terapia adaptativa, variando el tratamiento y aplicando otro como puede ser la radioterapia, frente a la que estas células no serían resistentes.

Viendo esto, es notoria la importancia de disponer de mecanismos para “predecir” la evolución de un tumor, con el fin de poder planificar qué medidas llevar a cabo para eliminarlo o, si no es posible, frenar su avance. En este punto es dónde entran en juego los simuladores de progresión tumoral; estos son herramientas informáticas que permiten simular la evolución de un grupo de células tumorales dadas unas condiciones iniciales concretas. Entre estos simuladores, destaca la herramienta **OncoSimulR**, sobre la que se va a enfocar este trabajo, por implementar funcionalidad extra, como la capacidad de simular tratamientos, o la libertad que ofrece para establecer el fitness de los genotipos celulares, permitiendo simulaciones mucho más complejas. Sin embargo, ni siquiera esta herramienta permite aún la simulación de una terapia adaptativa a lo largo del proceso de simulación, es en esta funcionalidad en la que se centrará principalmente este trabajo.

1.2. Objetivos

Como hemos comentado en el apartado anterior, el principal objetivo de este trabajo es lograr que en el programa **OncoSimulR** puedan simularse de forma efectiva los efectos de la terapia adaptativa en la evolución de un tumor, es decir, se debe permitir que las intervenciones que ya se pueden definir durante las simulaciones en este programa, puedan variar en función del estado en el que se encuentra el tumor a lo largo de la simulación. Para ello, se deben llevar a cabo distintas acciones que vamos a desglosar en objetivos de menor tamaño, por tanto los objetivos serán:

- Familiarizarse con la herramienta OncoSimulR en el estado en que se encuentra previamente al inicio del trabajo (especialmente el flujo general de código de la simulación y el funcionamiento de las intervenciones, que son los aspectos más relacionados con la funcionalidad que se quiere implementar).
- Aprender sobre R y C++, ya que son dos lenguajes con los que no estoy totalmente familiarizado al inicio de este trabajo.
- Completar el merge de las ramas anteriores solucionando todos los errores que aparezcan durante el proceso.
- Añadir la posibilidad de definir variables de usuario arbitrariamente complejas (que sean función de los parámetros de la simulación tales como población total, subpoblaciones de los genotipos, fitness, etc) tanto como salida en sí mismas como para emplearse en las intervenciones, pues serán el mecanismo principal que permitirá la implementación de la terapia adaptativa, como veremos en el apartado 3.

- Insertar la funcionalidad de las variables de usuario en el flujo general de código de la simulación, asegurándose de no afectar al funcionamiento de esta.
- Permitir que las intervenciones empleen estas nuevas variables de usuario, generando así la posibilidad de simular la terapia adaptativa.
- Generar una batería de pruebas extensa y lo más completa posible para comprobar el correcto funcionamiento de las variables de usuario y las intervenciones que las emplean.

1.3. Estructura del documento

A lo largo de este documento se explicará en detalle todo el trabajo llevado a cabo para lograr los objetivos definidos en el punto anterior. Debido a la extensión de este, se dividirá la memoria en diversos apartados:

- En primer lugar analizaremos el estado del arte, centrándonos en el punto en que se encuentra previamente a este trabajo la herramienta **OncoSimulR**, su funcionalidad disponible y el funcionamiento del algoritmo de simulación que implementa, así como el análisis detallado de las 2 ramas con funcionalidad recientemente implementada que deberán unificarse.
- Tras esto en el apartado de diseño, veremos la estrategia definida para lograr la funcionalidad deseada en el programa, y como se ha planificado cada paso que se ha de llevar a cabo para alcanzar los objetivos.
- Posteriormente, en el apartado de implementación, abordaremos el proceso de modificación del código del programa llevado a cabo para implementar los cambios definidos en el apartado de diseño. Este apartado incluye en detalle el proceso de unificación de ramas divergentes que se debió realizar previamente a la implementación de la nueva funcionalidad, que fue un proceso bastante más complejo de lo esperado inicialmente.
- Seguidamente, en el apartado de pruebas y resultados, explicaremos los tests llevados a cabo para asegurar el correcto funcionamiento de lo implementado, e ilustraremos la nueva funcionalidad con una serie de ejemplos de ejecución con sus correspondientes resultados.
- Por último, extraeremos unas breves conclusiones acerca del proyecto, y analizaremos las posibles líneas de trabajo futuro para extender aún más esta funcionalidad.

Cabe destacar que, si bien una de las partes más complejas del trabajo ha sido la unificación de las ramas anteriores, debido a los problemas surgidos de esta, este tema no aparece reflejado en el apartado de diseño, puesto que no ha tenido una parte extensa de planificación, ya que no se tenía previsto que apareciesen todos estos problemas. Por tanto este tema se tratará directamente en el apartado de implementación, explicando de forma detallada los problemas detectados y cómo se han ido solucionando estos.

2

Estado del Arte. OncoSimulR

Hemos visto en el apartado anterior, que la principal motivación de este proyecto es lograr la reproducir la terapia adaptativa durante un proceso de simulación de progresión tumoral. Para ello vamos a trabajar sobre el paquete OncoSimulR de R que implementa un simulador de este tipo.

Los simuladores de progresión tumoral son programas que permiten reproducir de forma artificial la evolución de un grupo de células tumorales dadas unas condiciones iniciales concretas. Son de gran interés en el ámbito de la biología pues permiten una gran obtención de datos acerca de la evolución modelos tumorales cuyo estudio siguiendo la vía teórica y matemática es excesivamente complejo. Permiten también en algunos casos (como es el caso de **OncoSimulR**) emular también los efectos que tendrían ciertos tratamientos o variaciones en las condiciones externas en la progresión de dichos tumores.

Dentro de los simuladores disponibles encontramos **OncoSimulR**, un paquete de R incluido dentro del proyecto Bioconductor, que fomenta el desarrollo de software de código abierto para el análisis de estudios biológicos. **OncoSimulR** ha sido desarrollado por Ramón Díaz Uriarte, Profesor Titular del Dpto. de Bioquímica de la Universidad Autónoma de Madrid, con el fin de simular la evolución de conjuntos de células tumorales con reproducción asexual, aunque actualmente, esta funcionalidad se ha extendido permitiendo simulaciones mucho más complejas, emulando modelos casi arbitrarios. Además, en una de las ramas más recientes, logra reproducir los efectos de ciertos tratamientos para evaluar su efectividad en la ralentización del avance del tumor.

Este paquete está escrito en los lenguajes R y C++, logrando una interfaz amigable con el usuario más acostumbrado al tema bioinformático mediante R, por ser un lenguaje muy común en este ámbito; pero logrando a la vez una buena eficiencia en la ejecución de código a través del lenguaje C++ en el que se implementan los algoritmos base de

la simulación, que tienen una mayor complejidad y coste computacional. Actualmente la funcionalidad de **OncoSimulR** incluye:

- Especificar la adaptabilidad de los genes mediante el “fitness” y las tasas de nacimiento y muerte con la función **allFitnessEffects**, en esta función se permite:
 - Especificar el fitness de cada genotipo de forma explícita siguiendo los modelos de **Bozic** (tasa de muerte fija y el fitness define el nacimiento) o de **McFarland** (tasa de nacimiento fija y el fitness determina la muerte).
 - Definir un fitness variable para los genotipos en función de la frecuencia de estos, es decir, según la cantidad de población (frecuencia absoluta), o la proporción frecuencia relativa) de cada genotipo que haya presente en el conjunto de células simulado.
 - Asignar de forma explícita de tanto tasa de nacimiento como tasa de muerte, sin seguir por tanto los modelos de Bozic y McFarland (En una de las ramas con funcionalidad más avanzada que la principal, explicada en 2.2.1)
 - Determinar la existencia o no de epistasia entre los genes, es decir, si la presencia de un determinado gen mutado favorece a otro, de este modo, el fitness de una célula con un determinado gen mutado aumentará si muta otro gen con el que tiene epistasia.
 - Especificar variaciones en el fitness en función del orden de mutación de los genes, es decir, permitir que un genotipo con 2 genes A y B mutados tenga fitness distintos si el gen A ha mutado primero, o lo ha hecho el gen B. ¿TODO:revisar?
- Emplear este fitness para la simulación de la progresión tumoral, definiendo para este además del “fitness”, las tasas de mutación iniciales, la población inicial y la presencia o no de genes ya mutados desde el inicio de la simulación. Esto se realiza mediante la función **OncoSimulIndiv**. Para realizar esta simulación el programa emplea el modelo **BNB de Mather et al** que se explicará en el punto 2.1.
- Emular los efectos de ciertos tratamientos o modificaciones en las condiciones externas en la evolución del tumor. Esto se hace mediante la funcionalidad de “intervenciones” implementada en otra de las ramas con funcionalidad extra sobre la rama principal, esta se explicará con más detalle en el punto 2.2.2.
- Mostrar mediante gráficos la evolución de prácticamente todos los datos de la simulación.
- Ejecución de varias simulaciones al mismo tiempo, permitiendo además la paralelización de estas simulaciones. Para ello se emplean las funciones **OncoSimulPop** y **OncoSimulSample**.

Toda esta funcionalidad permite una gran adaptabilidad al programa, haciéndolo muy útil para la simulación de escenarios muy complejos y enrevesados por permitir la especificación de forma prácticamente arbitraria de todas las condiciones de partida de la simulación.

2.1. Algoritmo BNB de Mather et al

Como hemos comentado en el apartado anterior, **OncoSimulR** emplea el algoritmo **BNB de Mather et al** para la simulación de la progresión tumoral. Este es un algoritmo de simulación basado en el uso de distribuciones binomiales y binomiales negativas para la actualización de las poblaciones. El algoritmo actúa de acuerdo a los siguientes pasos:

1. Inicializamos un número N de clases (en nuestro caso genotipos) en el tiempo inicial de la simulación $t = 0$. Para cada genotipo definimos una población inicial n_i con $i = 1, \dots, N$ y unas tasas de nacimiento, mutación y muerte (gi , γ_i y μ_i respectivamente).
2. Para cada clase (genotipo) generamos N números aleatorios r_i entre 0 y 1 siguiendo una distribución uniforme.
3. Para cada $i = 1, \dots, N$ se calcula un tiempo t_i , que representa el tiempo hasta la siguiente mutación. Este tiempo se calcula con la ecuación:

$$t_i = \frac{1}{R} \ln \left[\frac{r_i^{\frac{1}{n_0}} (R - W + 2g) - W - R + 2\gamma}{r_i^{\frac{1}{n_0}} (-R - W + 2g) - W + R + 2\gamma} \right]$$

Dónde R y W son:

$$R = \sqrt{(g - \gamma)^2 + (2g - 2\gamma + \mu)\mu}$$

$$W = g + \gamma + \mu$$

Esta ecuación solo tiene solución cuando se cumple que:

$$\left(\frac{R - W + 2\gamma}{R + W - 2g} \right)^{n_0} < r_i \leq 1$$

En caso contrario, quiere decir que la población se extinguirá antes de la siguiente mutación, y, por tanto, $t_i = \infty$.

4. Se busca el menor tiempo de mutación $t_m = \min(t_i)$, y la clase i_m a la que corresponde y se actualiza el tiempo de simulación $t = t + t_m$.
5. Se actualiza la población del genotipo i_m empleando 2 números aleatorios (uno binomial y otro binomial negativo), del siguiente modo:
 - a) Generamos un número aleatorio binomial $\tilde{m}$ con probabilidad de éxito $1 - \left(\frac{p_E(t)}{p_M(t)} \right)$ y con $n_{i_m} - 1$ términos.
 - b) Calculamos la población resultante de la clase (genotipo) que ha mutado $n_{i_m} = \tilde{n}$ siguiendo la ecuación:

$$n_{i_m} = \tilde{n} = \tilde{m} + 1 + \widetilde{NB}(\tilde{m} + 2, p_B(t))$$

Dónde $\widetilde{NB}(a, b)$ representa una binomial negativa de orden a y probabilidad de éxito b .

6. Se actualizan las poblaciones del resto de genotipos, para ello, para cada clase $i \neq i_m$ con $i, \in \{1, \dots, N\}$:
 - a) Generamos otro número aleatorio $\tilde{m}$ siguiendo una distribución binomial, con probabilidad de éxito $1 - \left(\frac{p_E(t)}{p_M(t)}\right)$ y n_i términos.
 - b) Si $\tilde{m} = 0$ entonces la clase se ha extinguido y la nueva población $n_i = \tilde{n} = 0$.
 - c) En caso contrario, la nueva población es:

$$n_i = \tilde{n} = \tilde{m} + \widetilde{NB}(\tilde{m}, p_B(t))$$

Dónde, al igual que antes, $\widetilde{NB}(a, b)$ representa una binomial negativa de orden a y probabilidad de éxito b .

7. Seleccionamos la mutación concreta que se ejecuta. Si esta genera un genotipo que no existe todavía, se crea una clase nueva para este genotipo $N+1$ con una población $n_{N+1} = 1$ y se establecen sus parámetros g_{N+1} , γ_{N+1} y μ_{N+1} . Si no, se suma uno a la población del genotipo que surge de la mutación.
8. Se eliminan las clases correspondientes a los genotipos cuyas poblaciones sean 0 tras las variaciones.
9. Se vuelve a 2 hasta que se cumpla la condición de parada.

La condición de parada puede definirse de diversos modos, con una población máxima o mínima, con un tiempo máximo o con una mutación específica. En el caso de **OncoSimulR**, la condición de parada empleada es un tiempo final.

2.2. Ramas con versiones divergentes

Además de la funcionalidad básica de simulación que proporciona el algoritmo **BNB de Mather et Al** explicado, **OncoSimulR** permite simulaciones más complejas mediante la adición de otra funcionalidad a este algoritmo. Algunos ejemplos de esto son la gran libertad para la definición de las tasas de nacimiento y muerte, o la posibilidad de simular el resultado de ciertos tratamientos, como se ha mencionado brevemente con anterioridad.

Estas funcionalidades, al ser muy recientes y haberse desarrollada simultáneamente, se encuentran, al inicio de este trabajo, en dos ramas diferentes del programa, cada una implementando una de las dos funcionalidades, que deben ser unificadas para proseguir con la nueva funcionalidad, pues se basa en parte en funcionalidad implementada en estas. Procederemos ahora a explicar brevemente las peculiaridades y funcionalidad concreta de estas dos ramas.

2.2.1. Birth y death rate

En esta rama se implementa la funcionalidad que permite definir de forma manual y arbitraria las tasas de nacimiento y muerte. La funcionalidad anterior a esta rama tan solo permitía la definición de un único parámetro “fitness”, que representaba la tasa de nacimiento (en el modelo de **Bozic**) o la de muerte (en el de **McFarland**), pero no se podían definir ambos de forma manual al mismo tiempo. Para incluir esto, esta rama contiene numerosos cambios en funciones básicas del algoritmo de simulación, que incluyen:

- **allFitnessEffects**: esta función es la que permite al usuario definir el fitness de los genotipos, por tanto, en esta rama, contiene cambios que permiten definir no solo un parámetro para cada genotipo (que antes era el fitness), sino dos, correspondientes a las tasas de nacimiento y muerte respectivamente.
- **evalAllGenotypes**: esta función se emplea para obtener los valores del fitness de todos los genotipos, por tanto en esta rama, implementa cambios para devolver dos valores para cada genotipo (correspondientes a las tasas de nacimiento y muerte) en lugar de uno solo, como previamente. Para ello incuye cambios además en otras funciones internas que gestionan el almacenamiento de los datos en las estructuras de C++.
- **OncoSimulIndiv**: la función principal de simulación se ve también afectada, pues debe permitir la simulación mediante un modelo distinto a los de **Bozic** y **McFarland** que ya se permitían, pues estos no necesitan definir ambas tasas. Por tanto se modifica esta función para introducir un nuevo modelo de simulación **Arb** (arbitrario) que permite introducir ambos valores.

Además, la rama incluye también modificaciones en numerosas estructuras en C++, especialmente en

- **fitnessLandscape_struct**: estructura que mapea los genotipos a su fitness, o, en esta rama, tanto a su tasa de nacimiento como de muerte.
- **fitnessEffectsAll**: estructura que contiene todos los datos para manejo del fitness, ahora debe incluir datos tanto para la tasa de nacimiento como de muerte.
- **spParamsP**: clase que almacena los datos de cada genotipo, tasa de mutación, fitness, población, etc. En esta rama en lugar del fitness incuye datos sobre la tasa de nacimiento y de muerte.

Al modificarse estas estructuras, se introducen también ligeros cambios en todas las funciones que las emplean, que deben también tenerse en cuenta.

2.2.2. Intervenciones

La funcionalidad correspondiente a la simulación de tratamientos mediante lo que en la aplicación **OncoSimulR** se llaman “intervenciones” está implementada en otra rama separada. En ella se permite definir ciertos cambios en la población o el fitness de uno o varios genotipos, que se llevarán a cabo cuando se cumpla una determinada condición o “trigger”. De este modo se puede emular el efecto que tendrían algunos tratamientos o intervenciones quirúrgicas en el desarrollo del tumor.

Esta funcionalidad se va a explicar de forma más detallada pues es la base sobre la que se implementarán los cambios para lograr simular la terapia adaptativa mencionada en el punto 1.2 (TODO).

Las “Intervenciones” están definidas por los siguientes parámetros:

- **ID**: identificador de la intervención que la diferencia de las otras.
- **Trigger**: expresión booleana que determina la condición que debe cumplirse en la simulación para que la intervención se lleve a cabo.
- **WhatHappens**: expresión que determina el cambio que se produce al ejecutarse la intervención. Puede ser un cambio en la población total, en la de uno o varios genotipos, o una variación en el fitness de alguno de ellos.
- **Periodicidad**: tiempo mínimo que debe pasar antes de que la misma intervención pueda ejecutarse de nuevo en caso de que esta se deba llevar a cabo varias veces.
- **Repeticiones**: número máximo de veces que puede ejecutarse la intervención a lo largo de la simulación.

Partiendo de esta definición, en la rama se implementa un algoritmo en la función **executeInterventions** del fichero **interventions.cpp** que controla la ejecución de las intervenciones mediante el proceso:

1. para cada intervención
 - a) Si se cumple el **Trigger**:
 - 1) Si ha pasado el tiempo mínimo de **Periodicidad** y quedan **Repeticiones** para la intervención:
 - a' Se ejecutan los cambios definidos en **WhatHappens**.

Este algoritmo luego se inserta en el flujo principal de código de la simulación, para que en cada ciclo de esta se compruebe si se deben ejecutar y en caso afirmativo se lleven a cabo.

En esta rama también se incluyen una nueva función de R que permite la definición de las propias intervenciones por parte del usuario, esta es:

```
createInterventions <- function(interventions , genotFitness ,  
  ⇨ frequencyType = "auto")
```

Que realiza las comprobaciones necesarias para asegurar que la definición de las intervenciones por parte del usuario es correcta, y prepara los datos de estas para pasarlos a C++.

El usuario definirá las intervenciones en R mediante una lista con todas las intervenciones que desee especificar, cada una de las cuales será a su vez otra lista, con los atributos necesarios para definirla. Un ejemplo de esta definición es:

```
interventions <- list(  
  list(ID          = "intOverA" ,  
        Trigger    = "n_B >= 5" ,  
        WhatHappens = "n_A = n_A * 0.1" ,  
        Repetitions = 0 ,  
        Periodicity = Inf  
  ) , list(  
        ID          = "intOverA2" ,  
        Trigger    = "(n_B >= 5) and (T > 4)" ,  
        WhatHappens = "n_A = n_A * 0.4" ,  
        Repetitions = Inf ,  
        Periodicity = Inf  
  )  
)
```

De igual modo, se incluye también en la rama la definición de varias estructuras en C++ para almacenar los datos correspondientes a estas intervenciones, estas estructuras son **Interventions** que contiene los datos de cada intervención, e **InterventionsInfo** que contiene los datos para gestionar el conjunto de intervenciones definidas para una simulación. Ambas estructuras están definidas en **interventions.h**

Por último, esta rama contiene también modificaciones ligeras en la función principal de simulación **OncoSimulIndiv** y muchas de sus sub-funciones tanto en R como en C++ para que estas tomen el argumento **interventions** de forma adecuada.

3

Diseño

3.1. Introducción. Terapia adaptativa y variables de usuario

Como hemos visto en la sección 1.1 (TODO), la base fundamental de la terapia adaptativa es la posibilidad de crear tratamientos específicos para determinados momentos en el desarrollo de un tumor. Dentro del programa **OncoSimulR** los tratamientos están simulados a través de las **intervenciones**. Por tanto, para simular la terapia adaptativa debemos lograr que estas intervenciones puedan depender del estado de desarrollo del tumor, es decir, del estado de la simulación en el momento concreto en que se va a ejecutar la intervención.

Para ello se ha decidido añadir al programa la posibilidad de definir variables de usuario, es decir, se ha incluido la posibilidad de que el usuario defina una serie de variables cuyo valor sea una función arbitrariamente compleja de distintos parámetros de la simulación. A lo largo de la simulación tumoral, estas variables se irán actualizando de acuerdo a la fórmula introducida por el usuario, haciendo que los valores vayan variando en función de la evolución del tumor.

Estas variables podrán luego ser empleadas para elaborar las expresiones que definen la acción a realizar en una intervención (como se ha visto en el punto 2 TODO), permitiendo así condicionar el efecto de una intervención al estado del tumor en el momento de la ejecución de esta, es decir, permitiendo la terapia adaptativa.

Con esto en mente procedemos al diseño de estas variables de usuario.

3.2. Definición de variables y reglas

A la hora de plantearse el diseño necesario para esta funcionalidad, lo primero que necesitamos saber es qué son y como se definen las variables de usuario que vamos a implementar.

Las variables de usuario son variables arbitrariamente complejas que un usuario puede definir a partir de combinaciones o funciones de algunas variables ya existentes en el programa. Para obtener estas variables arbitrariamente complejas vamos a necesitar de una serie de reglas que determinen el valor de estas variables en cada momento de acuerdo a las condiciones propuestas por el usuario para cada una de las variables.

Por tanto podemos determinar que por un lado tendremos un listado de variables, cada una de las cuales debera contener:

- **Nombre:** nombre de la variable de usuario que permite identificarla y diferenciarla de el resto de variables definidas.
- **Valor:** valor numérico de la variable en cada momento.

Por otro lado tendremos un listado con las reglas que permiten modificar y actualizar las distintas variables definidas. Estas reglas cuentan de:

- **ID:** identificador único de cada regla que permite diferenciarla del resto de reglas definidas.
- **Condition:** la condición que, si se cumple, hará que la variable de usuario se modifique.
- **Action:** acción que se llevará a cabo en caso de que la **Condition** se cumpla, es decir, es el conjunto de modificaciones a realizar a las variables de usuario en caso de que se cumpla la condición de la regla. podrá contener una o varias fórmulas que determinarán los nuevos valores de una o varias variables de usuario.

En este punto debemos mencionar también, qué variables del programa se ha decidido que sean empleables para la modificación de variables y definición de las reglas por parte del usuario y los motivos por los que se ha decidido esto. Las variables disponibles para la definición de las reglas son:

- **birthRate:** la tasa de nacimiento correspondiente a lcada genotipo, es decir,es un número que determina la probabilidad que tiene una célula con este genotipo de reproducirse, y por tanto aumentar su número total en 1 en un ciclo de tiempo.
- **deathRate:** la tasa de muerte correspondiente a cada genotipo, es decir, es un número que determina la probabilidad que tiene una célula con este genotipo de morir, y por tanto reducir su número total en 1 en un ciclo de tiempo.

- **mutationRate**: la tasa de mutación correspondiente a cada genotipo, es decir, es un número que determina la probabilidad que tiene una célula con este genotipo de mutar, y por tanto variar alguno de sus genes, pasando de ser de este genotipo a ser de otro genotipo distinto en 1 en un ciclo de tiempo.
- **N**: número total de células en la simulación, teniendo en cuenta todos los genotipos existentes.
- **n_x**: número de células de un determinado genotipo concreto, por ejemplo, **n_A** será el número de células del genotipo A, y **n_A_B** las del genotipo A_B
- **T**: tiempo transcurrido desde el inicio de la simulación, en segundos, con precisión de milisegundos.
- **Variables de usuario**: otras variables de usuario definidas en la misma simulación.

Estas variables se han añadido con la finalidad de dar a las variables de usuario la mayor flexibilidad posible para que el usuario las defina de acuerdo a sus necesidades, considerando todas las variables interesantes tanto para la terapia adaptativa como desde un punto de vista biológico para estudiar su evolución.

Las variables **N**, **n_x** y **T** se consideran necesarias para la terapia adaptativa, ya que permiten definir variables de usuario que se modifiquen de acuerdo a la evolución del tamaño del tumor (**N**), a la cantidad de las células de un determinado tipo, que se consideren más perjudiciales o sensibles a un determinado tratamiento (**n_x**) o al tiempo transcurrido (**T**). Estas variables definidas de acuerdo a estos atributos se podrían emplear luego para definir las intervenciones que permite el programa OncoSimulR, permitiendo adaptarlas de forma adecuada a las distintas combinaciones posibles de estos 3 atributos a lo largo de la simulación, generando así la posibilidad de simular terapia adaptativa. A estas 3 variables se les suman las propias variables de usuario, para poder así generar combinaciones aún más complejas que permitan simular escenarios altamente enrevesados.

Las otras variables **birthRate**, **deathRate** y **mutationRate**, se han añadido con una finalidad más informativa, ya que, a pesar de no ser tan interesantes desde el punto de vista de la terapia adaptativa (aunque pueden aplicarse en algunos casos), dan una información importante acerca de la adaptabilidad de los distintos genotipos a lo largo de la simulación, haciendo que el estudio de la evolución de variables de usuario que sean combinación de estas variables a lo largo de la simulación pueda tener un gran interés para el estudio tumoral.

3.3. Algoritmo de actualización

El algoritmo de actualización de las variables de usuario es a priori, bastante sencillo, pero su principal complejidad radica en su implementación e integración en el flujo de código principal, como veremos en la sección 4.

En rasgos generales el algoritmo de actualización es:

1. El usuario define las varibales de usuario que desea y las reglas para modificarlas
2. Se verifica que estan definidas correctamente
3. Cada unidad de tiempo muestreada en la simulación:
 - a) Para cada regla:
 - 1) Si se cumple la Condition:
 - a' Modificamos el valor de las variables de usuario según lo especificado por el usuario en el atributo Action
 - 2) Se pasa a la siguiente regla volviendo a 1)
 - b) Se procede a la ejecución de las intervenciones con los valores de las variables calculados

3.4. Definición de la estructura de salida

Para obtener los datos de evolución de las variables de usuario definidas en el tiempo a lo largo de la simulación, se deberán modificar la salida del programa de simulación para que incluya estos. Se debe añadir por tanto a la salida

- Una lista con los nombres (“ids”) de las variables de usuario creadas.
- Una matriz con los valores de las variables de usuario en cada unidad de tiempo muestreada (en el mismo orden que los nombres de las variables en en la lista de nombres de las variables de usuario).

La finalidad de añadir estos datos a la salida de la simulación es poder emplear las variables de usuario (que son arbitrariamente complejas) como datos de salida y no solo como valores a emplear en otros procesos como las intervenciones. Por ejemplo, obtener estos datos permite al usuario graficar la evolución en el tiempo de algunas variables de usuario creadas, lo que puede ser de gran interés para evaluar la evolución del tumor en la simulación. Además, la adición de estos datos en la salida facilitará enormemente las labores de testeo de la funcionalidad implementada.

4

Desarrollo

4.1. Introducción

En esta sección se va a explicar en primer lugar cómo se ha procedido con la unificación de las dos ramas principales con funcionalidad divergente de las que se partía, incluyendo la solución de los errores derivados del merge realizado, asíni como de errores previos de funcionalidad independientes del merge. Tras esto se procederá a la explicación de la implementación realizada para la funcionalidad definida en el apartado de diseño.

El desarrollo de los ficheros de código que componen esta funcionalidad se ha realizado en los lenguajes R y C++ por ser los lenguajes en los que ya está desarrollado el grueso del programa **OncoSimulR**. R se emplea para la interacción con el usuario, por ser un lenguaje muy común en bioinformática; por su parte C++ está presente para la ejecución del algoritmo de simulación, por er un lenguaje más eficiente para la ejecución de algoritmos complejos, reduciendo significativamente el coste temporal de ejecución de la simulación.

A lo largo de este apartado se mencionará reitradamente el uso de las librerías **Rcpp** y **ExprTk**.

- **Rcpp** es paquete del lenguaje R que permite el paso de datos y objetos entre los lenguajes R y C++, transformando los tipos de dato de uno de los lenguajes a sus equivalentes más próximos en el otro. De este modo, este paquete permite la comunicación fluida entre ambas partes del programa, la parte dedicada a la comunicación con el usuario (desarrollada en R) y la parte computacionalmente más constosa que implementa el grueso del algoritmo de simulación tumoral (desarrollada en C++).

- **ExprTk** es una librería definida en C++ que permite el parseo de expresiones matemáticas complejas. Esta librería ya estaba siendo empleada en el programa para el parseo de las expresiones que definen las intervenciones, pero en esta nueva funcionalidad va a ser empleada también para parsear las expresiones que permitirán la modificación de las variables de usuario en tiempo de simulación.

4.2. Unificación de Ramas

Cómo se ha explicado en el punto 2 (TODO) al iniciar este trabajo se partía de 2 ramas con versiones distintas del programa OncoSimulR cada una con una funcionalidad recientemente implementada en cada una de ellas. Estas 2 ramas debían unificarse para proceder a la implementación de la nueva funcionalidad sobre la versión combinada de ambas.

La unificación de ambas ramas se realizó de manera manual, ya que el merge automático proporcionado por la herramienta Git generaba un gran número de conflictos y no respetaba la funcionalidad de las ramas. Al proceder, se decidió realizar el merge sobre la rama que contenía la funcionalidad del birth y death rate (explicada en el punto 2 TODO) por ser la que más modificaciones introducía sobre el código base de la simulación, y sobre esta se introdujeron los cambios correspondientes a la rama con la funcionalidad de las intervenciones (explicada en el punto 2 TODO).

Para realizar la unificación de ambas ramas se procedió del siguiente modo:

1. Sobre la rama que se ha indicado anteriormente se añadieron los ficheros de código R y C++ exclusivos de la funcionalidad de intervenciones (intervention.cpp, intervention.h, intervention.R, multivariorant_hyergeometric.cpp y multivariant_hyergeometric.h), los ficheros de testeo de esta funcionalidad (test.intervention.R y test.Z-intervention.R) y los ficheros de documentación y viñetas que explican e ilustran el funcionamiento de esta.
2. Tras esto se procedió a la modificación de la función **updatePopulations** del fichero intervention.cpp, encargada de actualizar las poblaciones de los distintos genotipos tras la ejecución de una intervención, para que emplease el birth y death rate implementado en la funcionalidad de la otra rama.
3. Se actualizó el flujo de código principal del algoritmo BNB de Mahler (TODO: explicado en el punto 2) en el fichero BNB_nr.cpp para añadir las llamadas necesarias para añadir la funcionalidad correspondiente a la ejecución de las intervenciones.
4. Por último se modificaron las cabeceras y llamadas a todas las funciones del programa OncoSimulR para que tomaran de forma adecuada el argumento interventions, teniendo especial cuidado al tratar con los ficheros RcppExports.R, RcppExports.cpp y OncoSimulR_init.c, encargados de la comunicación entre los ficheros en R y en C++ mediante la librería Rcpp.

Posteriormente se realizó un merge automático con una tercera rama modificada por el tutor de este trabajo para incluir unas pequeñas modificaciones en la documentación del programa.

Al finalizar este proceso, se procedió a la comprobación de que la funcionalidad de ambas ramas era correcta en la rama combinada mediante la ejecución de los tests pertinentes, y a asegurar que el merge no ha afectado al resto de características del programa. Todo este testeo se explicará de forma más detallada en el punto 5.1 TODO.

4.3. Optimización del código de intervenciones

Durante la realización del merge de las ramas previas, se encontraron algunos problemas de optimización en el código de las intervenciones que hacían que el tiempo de ejecución fuese más alto de lo deseado, por tanto antes de proseguir con la nueva funcionalidad se procedió a solucionar esto.

El principal problema detectado en este aspecto eran fragments de código que se ejecutaban en todas las iteraciones, independientemente de si se realizaban intervenciones o no, cuando solo era necesaria su ejecución cuando estas si se realizaban. Si bien estos fragmentos de código no eran en sí mismos muy costosos coimputacionalmente, en una simulación de gran tamaño, con un gran número de iteraciones (como las que se realizan habitualmente en est programa), estos fragmentos se estarían ejecutando de forma innecesaria un enorme número de veces, haciendo que la variación en el tiempo de ejecución sí fuese bastante significativo.

Los cambios realizados, por tanto, fueron:

- Modificación de la función **executeInterventions** de interventions.cpp:
 - Cambiamos la función para que devuelva true si ha habido una intervención y false en caso contrario en lugar de devolver void como hasta ahora. Esto nos permite desde el algoritmo principal saber si ha habido o no intervención para ejecutar los fragmentos de código necesarios, además nos permite desde fuera obtener los tiempos en que se ejecutan las intervenciones, facilitándonos el testeo posteriormente.
 - Hacemos que en la función solamente se llame a **updatePopulations** (que actualiza las poblaciones de cada genotipo) en los casos en los que se ha ejecutado alguna intervención, puesto que son los únicos casos en que las poblaciones pueden haber cambiado.
- Modificamos también la función **parseWhatHappens** para que devuelva void en vez de true/false. Antes devolvía true si se ejecutaba sin errores y en caso de error lanzaba una excepción y devolvía false, lo cual no tenía sentido, por tanto ahora no devuelve nada y en caso de error simplemente lanza una excepción.

Tras esto de nuevo procedemos a comprobar que la funcionalidad es correcta mediante los tests explicados en el punto 5 TODO, y procedemos a comenzar con la nueva funcionalidad.

4.4. Implementación de variables de usuario y reglas

4.4.1. En R

Desde R debemos hacer posible que el usuario pueda definir las variables de usuario que desee, y las reglas que quiere que se emplee para su cálculo y actualización a lo largo de la simulación, así como permitir que pase estas como argumento a la función **OncoSimulIndiv** de OncoSimulR, que es la función responsable de llevar a cabo la simulación.

Para ello en primer lugar vemos como se deben definir las variables de usuario y las reglas en R:

- **Variables de usuario:** las variables de usuario hemos visto en el punto 3.2 que simplemente contienen un nombre que identifica a la variable, y un valor numérico. Por tanto el usuario definirá en R una simple lista con todas las variables de usuario que desee crear para la simulación con estos atributos, del siguiente modo:

```
userVars <- list(  
  list(Name = "user_var_1",  
        Value = 0  
  ),  
  list(Name = "user_var_2",  
        Value = 0  
  ),  
  list(Name = "user_var_3",  
        Value = 0  
  )  
)
```

- Name: string que contiene el nombre que identificará a la variable, debe ser único para la variable.
 - Value: valor inicial que tomará la variable al inicio de la simulación.
- **Reglas:** del mismo modo hemos visto en el 3.2 que las reglas constan de un ID, un Condition y una Action. De igual forma el usuario definirá estas reglas mediante una lista en R de la forma:

```
rules <- list(  
  list(ID = "rule_1",  
        Condition = "T > 20",
```

```

        Action = "user_var_1 = 1"
    ), list(ID = "rule_2",
        Condition = "T > 30",
        Action = "user_var_2 = 2"
    ), list(ID = "rule_3",
        Condition = "T > 40",
        Action = "user_var_3 = 3; user_var_2 = 1"
    )
)

```

- ID: string identifica la regla y la distingue del resto, debe ser único para cada regla.
- Condition: expresión con valor true/false que determina si se ejecuta o no la regla. Puede emplear las variables especificadas en el punto 3.2.
- Action: una o varias expresiones con valor numérico separadas por “;” que determinan el valor que tomarán las variables de usuario en caso de que se ejecute la regla. Del mismo modo que el campo Condition, puede emplear las variables especificadas en el punto 3.2.

Partiendo de estas definiciones, creamos en R una serie de funciones que comprueban que el usuario ha especificado las variables de usuario y reglas de forma correcta y las adaptan para que puedan pasarse a C++ de forma correcta mediante la librería Rcpp. Estas funciones son en el caso de las variables de usuario:

- **check_same_name**: comprueba que en la lista definida no existen varias variables de usuario con el mismo nombre.
- **verify_user_vars**: comprueba que todas las variables de usuario definidas en la lista tienen todos los atributos necesarios (Name y Value).
- **createUserVars**: mediante llamadas a las 2 funciones anteriores comprueba que la lista de variables de usuario definida es correcta, y si lo es, la devuelve.

Y en el caso de las reglas:

- **check_double_rule_id**: comprueba que en la lista de reglas definida no hay 2 reglas con el mismo id.
- **check_action**: comprueba la correcta especificación de la expresión del campo Action, para ello comprueba que, si hay varias expresiones, estas están correctamente separadas por “;” y que cada una de las expresiones tiene la forma: <variable de usuario>= <expresión>.
- **verify_rules**: comprueba que las reglas contienen todos los atributos necesarios (id, Action y Condition), y que estos son correctos llamando a las 2 funciones anteriores.

- **transform_rule**: modifica las expresiones Action y Condition de las reglas, ya que aunque en estas las variables **n_X** (explicadas en 3.2) se especifican como **n_A**, **n_B**, etc; en C++ los genotipos se definen con números y no con letras, por tanto esta función transforma **n_A**, **n_B**... en **n_1**, **n_2**...
- **adapt_rules_to_cpp**: mediante llamadas a la función anterior, modifica las expresiones action y condition de las distintas reglas definidas en la lista para adaptarlas a C++.
- **createRules**: mediante llamadas a **verify_rules** y a **adapt_rules_to_cpp** comprueba que las reglas definidas son correctas y las adapta a C++ devolviendo la lista de reglas ya transformada.

Por último, en R, se han modificado las llamadas y la cabecera de la función `OncoSimulIndiv` y de las demás funciones internas de `OncoSimulR` para que reciban de forma adecuada los nuevos argumentos `userVars` (lista de variables de usuario) y `rules` (listado de reglas).

4.4.2. En C++

Ya en C++ procedemos a desarrollar en TAD que maneja las variables de usuario y reglas definidas por el usuario en R. Para ello en primer lugar definimos las estructuras que contienen estos objetos. Para las reglas creamos la estructura **Rule** en C++, del siguiente modo:

```
typedef struct {  
    std::string id; // identifier of the rule  
    std::string condition; // condition that must be true for the  
        ↪ rule to execute  
    std::string action; // action to be performed when the condition  
        ↪ is satisfied  
} Rule;
```

Donde todos los campos son strings que corresponden exactamente a los atributos especificados en R por el usuario, explicados en el punto anterior 4.4.1.

Por otro lado definimos otra estructura en C++ llamada **UserVarsInfo**, que contiene las variables de usuario, y otros datos necesarios para operar adecuadamente con ellas. Esta estructura tiene el siguiente aspecto:

```
typedef struct {  
    std::map<std::string, double> userVars; // maps a user variable  
        ↪ name to its current value  
    std::vector<Rule> rules; // rules that apply to the group of user  
        ↪ variables  
    std::map<std::string, double> mapGenoToPop; // variable that maps  
        ↪ a genotype to its population  
} UserVarsInfo;
```

Donde:

- **userVars** es un mapa cuyas claves son strings con los nombres de las variables de usuario definidas y los valores son números reales que definen el valor de las distintas variables.
- **rules** es un listado con las reglas que controlan la actualización de las variables, definidas como estructuras Rule definidas justo antes.
- **mapGenoToPop** es un mapa que contiene las poblaciones de todos los genotipos en un momento dado de la simulación, es necesario para poder operar con estos valores al actualizar las variables de usuario empleando las reglas.

Una vez tenemos estas estructuras definidas, procedemos a la elaboración de las distintas funciones que implementan la funcionalidad del TAD. Comenzando por algunas funciones muy triviales que crean, destruyen, comparan, imprimen e implementan alguna funcionalidad muy simple de estas estructuras:

- Función que rellena la estructura Rule:

```
Rule createRule(std::string id, std::string condition, std::
    ↪ string action);
```

- Función que rellena la estructura UserVarsInfo:

```
UserVarsInfo createUserVarsInfo(Rcpp::List Rules,
    Rcpp::List userVars,
    const fitnessEffectsAll& fitnessEffects,
    const std::vector<spParamsP>& popParams,
    std::vector<Genotype> Genotypes);
```

- Función que añade una variable de usuario al mapa de variables de usuario de UserVarsInfo:

```
UserVarsInfo addUserVar(UserVarsInfo uvif, std::string name,
    ↪ double value);
```

- Función que añade una regla al listado de reglas de UserVarsInfo:

```
UserVarsInfo addRule(UserVarsInfo uvif, Rule r);
```

- Función que compara dos reglas definidas por la estructura Rule:

```
int compareRules(Rule r1, Rule r2);
```

- Función que elimina una regla del listado de reglas de la estructura UserVarsInfo:

```
UserVarsInfo destroyRule(UserVarsInfo uvif, Rule r);
```

- Función que imprime por pantalla una regla definida por la estructura Rule:

```
void printRule(Rule r);
```

- Función que imprime por pantalla las variables de usuario y reglas contenidas en una variable del tipo UserVarsInfo:

```
void printUserVarsInfo(UserVarsInfo uvif);
```

- Función que comprueba que cada una de las subexpresiones separadas por “,” contenidas en el atributo Action de la estructura Rule están bien definidas, con la forma <userVar>= <expresión>:

```
bool isValid(std::string equation);
```

Por último definimos las funciones que implementan la funcionalidad principal del TAD, estas son **executeRules** y **parseAction** que, en conjunto, permiten la actualización de los valores de las variables de usuario siguiendo lo especificado en las reglas.

- **executeRules**:

```
void executeRules (UserVarsInfo& uvif,
                  double &currentTime,
                  const std::map<std::string, double>
                    ↪ birthMap,
                  const std::map<std::string, double>
                    ↪ deathMap,
                  const std::map<std::string, double>
                    ↪ mutationMap);
```

Esta es la función principal que implementa el algoritmo de actualización de las variables de usuario explicado en el apartado 3.2. Para ello hace uso de la librería `exprtk` para parsear la expresión booleana contenida en el campo **Condition** para determinar si una regla debe ejecutarse o no, y, en caso afirmativo llama la segunda función mencionada **parseAction** para ejecutar la modificación de las variables pertinentes. Los parámetros que recibe esta función son:

- **uvif**: estructura `UserVarsInfo` (explicada al inicio de este punto) que contiene el listado de variables de usuario y reglas definidas para la simulación en ejecución. Se emplea para acceder a las reglas y variables de usuario, así como para añadir las variables de usuario a la tabla de símbolos de la librería `exprtk` para poder emplearlas en el parseo de las expresiones contenidas en las reglas. Contiene además también el campo **mapGenoToPop** con las poblaciones asociadas a cada genotipo, que se deben añadir también a la tabla de símbolos (corresponden a las variables **n_x**) y son necesarias para calcular la población total **N**.
- **currentTime**: tiempo actual de la simulación en el ciclo en que se está ejecutando la función. Se emplea para añadirlo como variable a la tabla de símbolos de `exprtk` para emplearse en el parseo de expresiones. Corresponde a la variable **T** explicada en el punto 3.2.
- **birthMap**, **deathMap** y **mutationMap**: mapas que contiene las tasas de nacimiento, muerte y mutación de todos los genotipos presentes en el momento actual de la simulación. Se añaden como variables a la tabla de símbolos de `exprtk`. Corresponden a las variables **birthRate**, **deathRate** y **mutationrate** respectivamente explicadas en el punto 3.2.

Conociendo estos datos, la función opera de la siguiente manera:

Algorithm 1 `executeRules`

Rellenamos la tabla de símbolos de `exprtk` con las variables mencionadas en el apartado 3.2 para que la librería pueda operar con ellas al parsear la **Condition**.

for regla **in** `uvif.rules` **do**

Parseamos **regla.Condition** con `exprtk` obteniendo **true/false**

if `regla.Condition == true` **then**

Llamamos a **parseAction**

end if

end for

▪ **parseAction**:

```
void parseAction(UserVarsInfo& uvif ,
                Rule rule ,
                double currentTime ,
                const std::map<std::string , double>
                    ↪ birthMap ,
                const std::map<std::string , double>
                    ↪ deathMap ,
                const std::map<std::string , double>
                    ↪ mutationMap);
```

Esta función se encarga de parsear el campo **Action** de la regla mediante `exprtk` y modificar el listado de variables de usuario definidas según lo indicado en este campo. En este caso los parámetros que recibe son muy similares a los de la función

anterior **executeRules**, pero añadiendo **rule**, que contiene la regla concreta que se va a ejecutar. Esta segunda función tiene la siguiente estructura:

Algorithm 2 executeRules

Rellenamos la tabla de símbolos de `exprtk` con las variables mencionadas en el apartado 3.2 para que la librería pueda operar con ellas al parsear la **Action**.

Dividimos la string **rule.action** en **tokens** separados por “,” (cada token define la actualización de una variable)

for each token **do**

 Separamos la string que define la asignación por el “=” obteniendo el **nombreVariable** y la **expresión**

 Parseamos la **expresión** con `exprtk` obteniendo el **valor** numérico al que equivale
 `uvif.userVars[nombreVariable] = valor`

end for

4.5. Integración en el flujo principal de código

Una vez definidas la funcionalidad de las variables de usuario y las reglas en el TAD anteriormente explicado, se procede a la integración de esta en el flujo principal de código de la simulación tumoral. Para ello se han incluido fragmentos de código que ejecutan las funciones de actualización de las variables de usuario dentro de la función **nr_innerBNB** del fichero **BNB_nr.cpp**, que es la que implementa el algoritmo BNB de Mahler explicado en el punto 2 (TODO).

La actualización de las variables de usuario se incluye dentro de esta función, de manera que se ejecute una vez por cada ciclo de muestreo de la simulación. Con el fin de poder simular la terapia adaptativa, es necesario poder emplear estas variables de usuario calculadas en la ejecución de las intervenciones, por tanto, esta actualización debe realizarse antes de que estas se ejecuten en cada ciclo. Finalmente se ha decidido realizar la actualización justo en el punto entre la actualización de las poblaciones de los genotipos según las tasas de nacimiento, muerte y mutación, y la ejecución de las intervenciones; de este modo las variables de usuario se actualizan de acuerdo a los datos temporalmente más cercanos posibles a la ejecución de las intervenciones, que es, por el momento, la principal funcionalidad para la que se van a emplear estas variables.

Se valoró la posibilidad de recalcular de nuevo las variables de usuario después de la ejecución de las intervenciones, pues estas pueden variar ciertos datos tales como la población, que afectarían al valor de estas variables. Sin embargo, esta opción se terminó descartando puesto que, al modificar las variables 2 veces por ciclo, se estaría aumentando notablemente el coste computacional del algoritmo, proporcionando además una información que, si bien es más precisa, no genera un beneficio suficientemente significativo como para justificar el coste.

Para realizar la actualización de las variables en el algoritmo de simulación principal mencionado, añadimos a este el siguiente fragmento de código:

```

std::map<std::string, double> birthMap = evalFVarsFitness(
    ⇨ fitnessEffects, Genotypes, popParams, "birth");
std::map<std::string, double> deathMap = evalFVarsFitness(
    ⇨ fitnessEffects, Genotypes, popParams, "death");
std::map<std::string, double> mutationMap = evalFVarsFitness(
    ⇨ fitnessEffects, Genotypes, popParams, "mutation");
if(rules_length > 0 && userVars_length > 0){
    uvif.mapGenoToPop = evalFVars(fitnessEffects, Genotypes,
        ⇨ popParams, true);
    executeRules(uvif, currentTime, birthMap, deathMap,
        ⇨ mutationMap);
    auxValues = {};
    for (auto &item : uvif.userVars){
        auxValues.push_back(item.second);
    }
    auxValues.push_back(currentTime);
    userVarValues.push_back(auxValues);
}

```

En este fragmento cabe destacar la creación y uso de la función **evalFVarsFitness** que permite acceder a las tasas de nacimiento, muerte y mutación de los distintos genotipos presentes en este momento de la simulación; que se deben pasar como parámetros a **executeRules** para poder añadirse a la tabla de símbolos de `exprtk`. Vemos que de forma similar se emplea también la función **evalFVars**, que ya existía con anterioridad, para obtener los valores de las poblaciones de los distintos genotipos, valores que también se deben pasar como parámetro a **executeRules**. Una vez obtenidos todos estos valores necesarios, se procede a la llamada a **executeRules** para actualizar las variables, almacenando los valores de las variables resultantes en vectores auxiliares para posteriormente poder devolverlos a la salida.

Además de estas adiciones al algoritmo, se ha modificado también su estructura de salida para que incluya una lista con los nombres de las variables de usuario creadas durante la simulación, y una matriz con los valores que toman las variables en cada unidad de tiempo de la simulación (cada fila es una lista con los valores de las distintas variables para una unidad de tiempo, en el mismo orden en que aparecen en la lista con los nombres de las variables), esta matriz se rellena con los valores que se han ido almacenando en el vector auxiliar mencionado anteriormente.

Por último, para finalizar esta integración en el flujo principal de código, se han modificado los parámetros de entrada de todas las funciones en R de `OncoSimulR` para que reciban de forma adecuada los parámetros **userVars** y **rules**, y se han actualizado los ficheros `RcppExports.R`, `RcppExports.cpp` y `OncoSimulR_init.c`, para que estos mismos parámetros se pasen a C++ de forma adecuada.

4.6. Variables de usuario en las intervenciones. Terapia adaptativa

Como hemos visto en la sección 3.1, la finalidad principal de la creación de las variables de usuario es lograr la simulación de la terapia adaptativa. Para ello, ahora que contamos con la funcionalidad completa de las variables de usuario, se debe lograr que estas puedan emplearse para definir las expresiones que determinan las acciones a realizar en una intervención.

Por tanto, se ha incluido estas variables en la funcionalidad de las intervenciones. Para ello se han modificado las funciones **executeInterventions** y **parseWhatHappens** del fichero **interventions.cpp**, que controlan la ejecución de las intervenciones en la simulación. Ambas funciones reciben unas modificaciones muy similares que consisten en:

1. Modificamos ambas funciones para que para que reciban como argumento la estructura `userVarsInfo` con los datos de las variables de usuario.
2. Añadimos en ambas un pequeño fragmento de código para introducir las variables de usuario y sus valores a la tabla de símbolos de `exprtk` permitiendo así que se puedan emplear en el parseo de expresiones de las intervenciones.
3. Modificamos las cabeceras y llamadas a estas 2 funciones de forma adecuada para que incluyan `userVarsInfo` en todas las llamadas.

Con estos cambios se finaliza el desarrollo de la funcionalidad y se procede a las pruebas para comprobar su correcto funcionamiento.

5

Pruebas y Resultados

5.1. Comprobación de funcionalidad previa

Antes de proceder a introducir toda la nueva funcionalidad explicada a partir del punto 4.4, y tras realizar la unificación de las 2 ramas de las que se partía y la solución de los problemas de optimización explicados en 4.3 ,aseguramos que la funcionalidad anterior no se ha visto afectada mediante el uso de la batería de tests ya disponibles para el programa **OncoSimulR**. Esta batería de tests incluye por una lado unos tests manuales muy extensos y costosos computacionalmente, y otro grupo de tests que comprueban la funcionalidad básica del programa mediante el paquete **testthat** del lenguaje R. Al realizar esto se detectaron una serie de errores previos al merge en una de las ramas. Los errores detectados están localizados en los tests de la funcionalidad de intervenciones, y son errores en los propios tests y no fallos de funcionalidad. Para solucionar estos errores:

- Se modifica la salida del algoritmo de simulación BNB implementado en la función **nr_BNB_Algo5** para que incluya una lista con los tiempos de la simulación en los que se ejecutan intervenciones (esto nos permite buscar los puntos exactos donde se realizan las intervenciones en los tests). De este modo la salida de la función principal de simulación **OncoSimulIndiv** ahora incluye el campo **x\$other\$interventionTimes** con estos tiempos (donde “x” es la variable donde se almacena la salida de la función).
- Adelantamos el punto de ejecución de las intervenciones en flujo principal del código de la simulación realicen antes de rellenar las estructuras de salida. Con esto conseguimos que al actualizarse las poblaciones y tasas de nacimiento y muerte al final de cada ciclo de simulación, estas incluyan los cambios realizados

por las intervenciones; antes de esta modificación, los cambios que realizaban las intervenciones no se veían reflejados en las poblaciones mostradas a la salida hasta el tiempo correspondiente a la siguiente iteración de la simulación, lo que generaba un desfase entre lo que se testeaba (que emplea los datos de salida) y las poblaciones internas empleadas en la simulación (que sí incluían los cambios realizados por las intervenciones).

- Comentar la comprobación de `totPopSize != totalPop` en `reduceTotalPopulation` (`interventions.cpp`) porque al haberlo adelantado `totPopSize` no está actualizado.
- Añadimos un fragmento de código para eliminar los genotipos con población 0 después de realizar intervenciones. Esto estaba generando un error pues algunas operaciones de la simulación no se pueden realizar con poblaciones 0.
- Modificamos los tests ya existentes de intervenciones para adaptarlos a estos nuevos cambios y comprobamos que todos los tests se pasan correctamente. Estas modificaciones consisten principalmente en hacer que se empleen los tiempos almacenados en `x$other$interventionTimes` para buscar los puntos en los que se realizan intervenciones y comprobar que estas son correctas, en lugar de buscarlas recorriendo la estructura de salida con las poblaciones en cada unidad de tiempo, pues este método no permitía un testeo correcto además de ser mucho menos eficiente.

Por último, tras implementar toda la nueva funcionalidad (explicada a partir del punto 4.4) volvemos a ejecutar toda la batería de tests para asegurar, de nuevo, que estos cambios no han afectado al correcto funcionamiento de la funcionalidad previa.

5.2. Tests de nueva funcionalidad

Para probar el correcto funcionamiento de la nueva funcionalidad implementada que incluye la creación de variables de usuario y su actualización, así como la simulación de la terapia adaptativa mediante la inclusión de estas variables en las intervenciones; se ha ampliado la batería de tests del programa (concretamente los tests que emplean la herramienta `testthat` incluyendo un nuevo documento de tests `test.user_var.R` que prueba la funcionalidad de las variables de usuario, y se ha ampliado el documento de tests `test.intervention.R` que incluye los tests sobre intervenciones, para añadir los casos en que estas dependen de los valores contenidos en variables de usuario. Ambos ficheros están incluidos en el directorio `tests/testthat`.

5.2.1. Variables de usuario

Como hemos comentado los tests que comprueban el correcto funcionamiento de las variables de usuario están contenidos en el fichero `test.user_var.R`, estos tests contienen las siguientes comprobaciones.

- Las variables de usuario se crean correctamente
- 2 variables no pueden tener el mismo nombre
- Las reglas para la actualización de las variables se crean correctamente
- 2 reglas no pueden tener el mismo ID
- Al ejecutarse las reglas, las variables de usuario se modifican de forma correcta (en función de la variable T)
- Al ejecutarse las reglas las variables de usuario se modifican de forma correcta (en función de la variable N)
- Al ejecutarse las reglas las variables de usuario se modifican de forma correcta (en función de las poblaciones por genotipo `n_x`)
- Al ejecutarse las reglas las variables de usuario se modifican de forma correcta (en función de la otras variables de usuario)

5.2.2. Intervenciones con variables de usuario

Una vez hemos comprobado que las variables de usuario funcionan de forma adecuada, ampliamos los tests del fichero **test.intervention.R** para asegurar que las intervenciones funcionan de forma correcta cuando depende de las variables de usuario creadas. Para ello añadimos 2 nuevos tests en este fichero para comprobar:

- Las intervenciones se ejecutan de forma correcta cuando el **Trigger** (condición de ejecución de la intervención) depende de variables de usuario.
- Las intervenciones se ejecutan de forma correcta cuando el **WhatHappens** (modificación en poblaciones o tasas realizada por la intervención) depende de variables de usuario.

5.3. Resultados

Tras todo el trabajo realizado, en esta sección vamos a comprobar que, efectivamente, los resultados obtenidos cumplen con lo esperado e, incluso, se han logrado resultados positivos que no se habían planteado inicialmente como objetivos del trabajo.

5.3.1. Variables de usuario como datos de interés a la salida

Al implementar las variables de usuario, como hemos comentado anteriormente, se permite obtener un enorme número de datos arbitrariamente complejos de la simulación

a la salida. Estos pueden ser de gran interés para llegar a un entendimiento más profundo y detallado de lo ocurrido durante la simulación. En esta sección se van a plantear algunos ejemplo de ejecución en los que se saca partido a esta funcionalidad.

Representación de la proporción de cada genotipo sobre la población total

Comenzamos con un ejemplo muy sencillo en el que genramos un grupo de variables de usuario que almacenan la proporción de cada genotipo existente sobre el total de la población, es decir, matemáticamente cada una de estas variables es, para cada genotipo “X”:

$$proporcionX = n_X/N$$

Dónde “n_X” es la población correspondiente al genotipo X, y “N” la población total.

Con estas variables de usuario definidas iniciamos una simulación con 5 genotipos: **WT** (el inicial, sin mutaciones), **A**, **B**, **A,B** y **A,C**. Asignamos a cada uno de ellos sus fitness y sus poblaciones iniciales (estos detalles se pueden ver en detalle en el código adjunto en el anexo ... TODO con el código para ejecutar esta simulación), e iniciamos la simulación llamando a **OncoSimulIndiv**. En este caso simularemos tan solo un tiempo de 10 segundos, pues es suficiente para ver los datos que nos proporcionan las variables de usuario.

Representando gráficamente los resultados obtenidos en las poblaciones de los genotipos vemos lo siguiente:

Si ahora observamos tambien los resultados de las variables de usuario que representan la proporción de las poblaciones:

Podemos observar claramente que los genotipos **AB** y **AC** son apenas relevantes comparados con los otros, y además se aprecia que el genotipo **B** aumenta de forma proporcional al descenso en la población del genotipo **A**.

Representación de la diferencia entre la tasa de nacimiento y muerte

Vamos ahora con otro ejemplo para analizar más profundamente el uso de variables de usuario. En este caso las que vamos a definir son variables que contengan el valor de la diferencia entre la tasa de nacimiento y muerte de los distintos genotipos. Este valor, por tanto, nos mostrará si se debería esperar que la población de un determinado genotipo crezca (si la diferencia es positiva) o disminuya (si es negativa). La fórmula para calcular estas variables de usuario es muy sencilla:

$$diferenciaTasasX = b_X - d_X$$

Dónde “b_X” es la tasa de nacimiento correspondiente al genotipo X, y “d_X” la de muerte. Del mismo modo que en el ejemplo anterior establecemos los datos de la simulación (visibles en el anexo ... TODO en el código para reproducir el ejemplo) que en este caso contará con 3 genotipos **WT** **A** y **B**, y, para que los datos de las tasas sean variables y

más interesantes de analizar, definiremos el fitness como dependiente de las frecuencias de los genotipos, funcionalidad que también permite la herramienta **OncoSimulR**.

Representando los resultados obtenidos con las variables de usuario que representan la diferencia de tasas:

Viendo esto podemos estimar que a partir del tiempo 20-25 los genotipos **A** y **B** comenzarán a crecer, el segundo más rápidamente que el primero. **A** debería comenzar a caer alrededor del tiempo 50, cuando la diferencia de tasas pasa a ser negativa, mientras que **B** lo hará más tarde en el tiempo 100 cuando su diferencia de tasas se estabiliza por debajo de 0. Por su parte esperamos que **WT** comience a decrecer alrededor del tiempo 40.

Ahora observamos la evolución de las poblaciones:

Comprobamos que, de forma bastante aproximada los resultados son los esperados; las pequeñas variaciones se deben al componente aleatorio que existe en la evolución de las poblaciones. Por tanto, la observación de la diferencia de tasas que nos proporcionan las variables de usuario nos permite ver unos datos objetivos para predecir la evolución poblacional excluyendo la aleatoriedad del algoritmo.

5.3.2. Terapia Adaptativa

Procedemos ahora a analizar el resultado de la funcionalidad correspondiente al objetivo principal de este trabajo, que es lograr simular la terapia adaptativa. Para ello procedemos con una serie de ejemplos de ejecución que nos permitirán ver el funcionamiento de esta.

Selección de tratamiento según el genotipo más adaptado

Comenzamos con un ejemplo en el que se adaptará el tratamiento para enfocarse en el genotipo más adaptado y que, por tanto más posibilidades tiene de desarrollarse. Para ello partimos del mismo ejemplo que en el punto anterior (5.3.2) en el que calculamos la diferencia de las tasas de nacimiento y muerte, para de esta forma estimar cual es el genotipo con más posibilidades de proliferar. Además añadimos un mínimo poblacional de 1000 células para detectar determinado genotipo, es decir, que si la población de un genotipo no es superior a 1000 no se tratará, pues no se considera suficiente para ser detectado.

Tras esto definimos una serie de intervenciones para “perjudicar” el desarrollo del genotipo que tenga dicho valor más alto, estas intervenciones las definimos del siguiente modo:

```
interventions <- list(  
  list(ID           = "i1",  
        Trigger     = "genADiff > genBDiff and genADiff > genWTDiff",  
        ⇨           = "  
  )
```

```
WhatHappens = "n_A = n_A*0.5",
Periodicity = 10,
Repetitions = Inf
), list (ID = "i2",
Trigger = "genBDiff > genADiff and genBDiff > genWTDiff
    ↪ ",
WhatHappens = "n_B = n_B*0.5",
Periodicity = 10,
Repetitions = Inf
)
)
```

Tras esto iniciamos la simulación (el código para reproducir este ejemplo está en el anexo... TODO), obteniendo los siguientes resultados:

Vemos que efectivamente las bajadas bruscas en la población que corresponden a las intervenciones se producen al comienzo en **WT** que comienza siendo el más adaptado pues tiene mayor diferencia entre las tasas, pero a partir del tiempo 30 aproximadamente, estas pasan a realizarse sobre el genotipo **B**, que justo es a partir de ese punto cuando comienza a tener una diferencia entre tasas mucho más alta.

Simulación de situación verosímil

Por último vamos a simular un escenario complejo de terapia adaptativa intentando acercarnos lo máximo posible a lo que podría ocurrir en un caso real. Para ello establecemos en qué consistiría esta terapia adaptativa aplicable en la realidad:

1. Cada cierto tiempo el paciente tiene una revisión dónde se analiza el progreso de su tumor.
2. Si se detectan unos valores anormales se comienza un tratamiento base para tratar de frenar el avance de este.
3. Si se observa un crecimiento anormalmente grande de un tipo determinado de células se cambia el tratamiento que se estaba aplicando hasta el momento por otro más enfocado a las células de ese tipo.
4. Si el tumor sobrepasa un cierto tamaño preestablecido se plantea la necesidad de realizar una intervención quirúrgica para tratar de eliminarlo.

Para este ejemplo además consideraremos preocupantes las células de genotipos distintos al **WT**, pues este es el inicial sin mutaciones, y, por tanto, no se considera peligroso.

Todo el código para reproducir este ejemplo se encuentra en el anexo ... TODO.

Procedemos entonces a tratar de simular este escenario con 3 genotipos **WT**, **A** y **B**, para ello definimos en primer lugar una serie de variables de usuario que serán:

- **measure**: flag que determina si toca realizar una medición o no (revisión del paciente).
- **lastTime**: almacena el último tiempo en que se ha realizado una medición.
- **lastMeasuredA**: valor de la población del genotipo A en la última medición.
- **lastMeasuredB**: valor de la población del genotipo B en la última medición.
- **previousA**: valor de la población del genotipo A en la medición anterior (permite luego calcular las diferencias para ver el crecimiento).
- **previousB**: valor de la población del genotipo B en la medición anterior (permite luego calcular las diferencias para ver el crecimiento).
- **treatment**: variable que determinará el tratamiento a aplicar.

Estas las modificaremos de acuerdo a las siguientes reglas:

1. Si “tiempo de simulación” - **lastTime** <10 (no han pasado 10 segundos): **measure** = 0 (no hay que medir).
2. Si “tiempo de simulación” - **lastTime** >10 (han pasado 10 segundos): **measure** = 1 (hay que medir) y **lastTime** = “tiempo de simulación”.
3. Si **measure** == 1 (hay que medir): **previousA** = **lastMeasuredA**; **previousB**=**lastMeasuredB**; **lastMeasuredA** = **n_A** y **lastMeasuredB** = **n_B** (almacenamos los datos medidos).
4. Si no se cumple ninguna de las condiciones siguientes (Si true): **treatment** = 0.
5. Si **lastMeasuredA** + **lastMeasuredB** >100 (tumor detectable): **treatment** = 1.
6. Si **lastMeasuredA** - **previousA** >500 (**A** ha crecido mucho): **treatment** = 2.
7. Si **lastMeasuredB** - **previousB** >500 (**B** ha crecido mucho): **treatment** = 3.
8. Si **lastMeasuredA** - **previousA** >500 AND **lastMeasuredB** - **previousB** >500 (**A** y **B** han crecido mucho): **treatment** = 4.

Ahora podemos definir las intervenciones en base al valor de **treatment** del siguiente modo:

```
interventions <- list(
  list(ID      = "basicTreatment",
        Trigger = "treatment == 1",
        WhatHappens = "N = 0.8*N",
        Periodicity = 10,
        Repetitions = Inf
  ), list(ID      = "treatmentOverA",
        Trigger = "treatment == 2 or treatment == 4",
```

```
        WhatHappens    = "n_B = n_B*0.3",
        Periodicity    = 20,
        Repetitions    = Inf
    ), list (ID         = "treatmentOverB",
        Trigger        = "treatment == 3 or treatment == 4",
        WhatHappens    = "n_B = n_B*0.3",
        Periodicity    = 20,
        Repetitions    = Inf
    ), list (ID         = "intervention",
        Trigger        = "lastMeasuredA+lastMeasuredB > 5000",
        WhatHappens    = "N = 0.1*N",
        Periodicity    = 70,
        Repetitions    = Inf
    )
)
```

Establecemos que el tratamiento básico se puede realizar cada 10 segundos, los específicos sobre **A** y **B** al ser más agresivos establecemos que sólo se pueden realizar cada 20 segundos, por último, la intervención quirúrgica no se puede realizar de forma muy habitual, por lo que establecemos que puede ocurrir cada 70 segundos, y se realizará cuando el conjunto de células peligrosas supere 5000.

Con todo esto comenzamos la simulación, obteniendo el siguiente resultado poblacional:

Podemos ver como a partir de aproximadamente el tiempo 100 comienza a haber pequeñas bajadas bruscas en todos los genotipos al mismo tiempo, correspondientes al tratamiento base. Luego alrededor del tiempo 150 el genotipo **B** aumenta demasiado y sufre una bajada más grande por su tratamiento específico; y, finalmente, alrededor del tiempo 160-170 las poblaciones **A** y **B** han crecido lo suficiente como para que se lleve a cabo una intervención, por lo que se desploman todas las poblaciones.

Este es por tanto un clarísimo ejemplo de una terapia adaptada al progreso del tumor, y por tanto vemos que se ha logrado con éxito la simulación de la terapia adaptativa.

6

Conclusiones y trabajo futuro

6.1. Conclusiones

6.2. Líneas de trabajo futuro

- Emplear variables de usuario en otras funcionalidades más allá de las intervenciones
- Permitir graficar variables de usuario en función del tiempo como una salida interesante de forma similar a la evolución de la población de los genotipos

Apéndices



Ejemplos de bloques y comandos útiles en LaTeX

A.1. Ejemplo de sección

La DARPA creó el protocolo de Internet [**ipv4sta**].

Citamos el acrónimo Field-Programmable Gate Array (FPGA).

Bitstream es una secuencia de bits.

La figura ?? se utiliza en la portada.



Figura A.1: Logo de la Universidad Autónoma de madrid.

Código A.1: Algoritmo de ordenación Quicksort

```
#include <stdio.h>

void quick_sort (int *a, int n) {
    int i, j, p, t;
    if (n < 2)
        return;
    p = a[n / 2];
    for (i = 0, j = n - 1;; i++, j--) {
        while (a[i] < p)
            i++;
        while (p < a[j])
            j--;
        if (i >= j)
            break;
        t = a[i];
        a[i] = a[j];
        a[j] = t;
    }
    quick_sort(a, i);
    quick_sort(a + i, n - i);
}
```

```
#include <stdio.h>

void quick_sort (int *a, int n) {
    int i, j, p, t;
    if (n < 2)
        return;
    p = a[n / 2];
    for (i = 0, j = n - 1;; i++, j--) {
        while (a[i] < p)
            i++;
        while (p < a[j])
            j--;
        if (i >= j)
            break;
        t = a[i];
        a[i] = a[j];
        a[j] = t;
    }
    quick_sort(a, i);
    quick_sort(a + i, n - i);
}
```

La ecuación de Euler ($e^{\pm i\theta} = \cos \theta \pm i \sin \theta$) es citada frecuentemente como un ejemplo de belleza matemática.

$$a^2 + b^2 = c^2 \tag{A.1}$$